

BUILD A LARGE LANGUAGE MODEL

Capítulo 1 - Understanding large language models (Entendendo grandes modelos de linguagem)

O que caracteriza um Large Language Model?

LLMs são treinadas com grandes quantidades de dados de texto, permitindo capturar contextos de informação mais profundos e sutilezas da linguagem humana comparado com abordagens anteriores (NLP).

LLM é uma rede neural feita para entender, gerar e responder textos com aspecto humano. São redes neurais profundas treinadas com gigantes quantidades de dados de texto, dados esses muitas vezes advindos de textos disponíveis publicamente na internet. O “Large” refere-se ao tamanho do modelo de parâmetros e imensos datasets em que são treinadas. Esses parâmetros são os “pesos ajustados” na rede que são otimizados durante treinamento para prever a próxima palavra na sequência. O next-word é sensível visto que aproveita a natureza sequencial da linguagem.

LLMs são usadas para geração de textos “inéditos”, tradução automática, criação de ficção, artigos, códigos de programação, chatbots e assistentes virtuais. Os LLMs são inestimáveis para automatizar qualquer tarefa que envolve análise e geração de texto.

LLMs feitas para tarefas e domínios específicos podem superar o desempenho de LLMs com propósito geral (como o Chat GPT que é feito para uma ampla gama de aplicações).

LLMs para tarefas específicas oferece vantagens principalmente em privacidade de dados. Desenvolver LLMs menores permite implementação diretamente nos dispositivos dos clientes (laptops, celulares e etc). LLMs menores podem reduzir latência, diminuir custos de servidor e garantir autonomia do desenvolvedor.

Qual a diferença entre IA, Machine Learning e Deep Learning?

Deep learning é um subconjunto de machine learning e IA mas que foca em redes neurais.

IA abrange um campo maior de criar máquinas que podem realizar tarefas que requerem inteligência humana, incluindo entender linguagens, reconhecer padrões, tomar decisões, ela inclui subáreas como machine learning e deep learning.

Deep learning abrange áreas das LLMs e GenAI, ela é basicamente machine learning com redes neurais. Ela é uma subárea de machine learning, focada em utilizar redes neurais com 3 ou mais camadas (deep neural networks) para modelar padrões complexos em dados. Ela não precisa de extração manual de características, entretanto assim como o aprendizado de máquina tradicional, ela requer coleção de rótulos que definem o que é algo e o que não é algo, que devem ser juntados por especialistas ou usuários.

Machine learning abrange áreas de Deep learning, ele é o algoritmo que aprende as regras automaticamente através de vários dados. Os algoritmos usados para implementar IA são o foco do machine learning. O aprendizado de máquina envolve criar algoritmos que podem aprender e fazer previsões ou decisões baseados em dados sem serem explicitamente programados. Ao minimizar o erro nas previsões em um dataset de treinamento, o modelo aprende a reconhecer padrões e características indicativas, por exemplo, do spam em e-mails. Em contraste com o deep learning, o machine learning tradicional requer extração manual de características, ou seja, humanos especialistas precisam identificar e selecionar as características mais relevantes para o modelo.

IA é um sistema com inteligência do tipo humana. Embora esteja dominada por aprendizado de máquina e deep learning, ela inclui outras abordagens (sistema baseado em regras, algoritmos genéticos, sistemas especialistas, lógica difusa/fuzzy, raciocínio simbólico).

Como os modelos GPT estão organizados?

Quais são as principais etapas do treinamento de um LLM?

O processo geral de criar uma LLM inclui pré-treino e afinação. O pré-treinamento refere-se a fase inicial onde um modelo LLM é treinado em um grande e diverso dataset para desenvolver um amplo entendimento da linguagem, ele serve como uma fonte fundamental que pode ser mais para frente refinada através da afinação (fine-tuning). A afinação é um processo onde o modelo é especificamente treinado em um dataset mais estreito e específico para tarefas particulares.

O primeiro passo em criar uma LLM é treiná-la em grandes montes de dados de texto (raw text). Esses textos são apenas regulares sem serem transformados em informação. Filtros podem ser aplicados como remoção de formato de caracteres ou documentos em linguagens desconhecidas. Nessa fase (pretraining) os LLMs usam auto-supervisionado aprendizado, onde o modelo gera seus próprios rótulos dos dados de entrada. Criamos assim uma base ou modelo de fundação.

Após esse treinamento, podemos treinar o LLM em dados rotulados (fine-tuning). As duas categorias mais populares de afinação são instruction fine-tuning e classification fine-tuning. Em instrução de afinação, o dataset rotulado consiste em instruções e pares de respostas, como uma consulta (query) para traduzir um texto acompanhado por textos corretamente traduzidos. Já em classificação de afinação, o dataset rotulado consiste em textos e rótulos de classe associados, por exemplo, e-mails associados como “spam” ou “não spam”.

Qual é o fluxo geral de funcionamento de um modelo de linguagem?

Anotações:

NLP para DNN:

- NLP é uma área da IA que procura fazer computadores entenderem, interpretar, gerarem e manipularem a linguagem humana, fazer a máquina trabalhar com textos e fala de criação humana. Mas como computadores trabalham bem com números eles podem ter dificuldades como ambiguidade das palavras, contexto, gírias e abreviações.
- Antes das redes neurais profundas o NLP era baseado principalmente em regras e estatísticas, mas tinha problemas visto que eram muitas regras e precisava de muita engenharia manual.
- Então vieram as DNN que mudaram as NLP visto que conseguiam aprender representações da linguagem automaticamente

Arquitetura da LLM:

- Chama de transformer, permite que esses modelos prestem atenção seletiva para diferentes partes da entrada quando fazem previsões, o que faz com sejam proficientes em lidar com nuances e complexidades da linguagem humana.