

GLOSSÁRIO

Glossário de Termos abordados no capítulo 1 do livro “Build a Large Language Model”

Afinação (Fine-tuning): Etapa posterior ao pré-treinamento em que o modelo é treinado com um conjunto de dados menor e mais específico para determinada tarefa.

Aprendizado auto-supervisionado: Forma de treinamento em que os próprios dados fornecem os alvos utilizados pelo modelo. No caso dos GPTs, a próxima palavra pode servir como alvo para o treinamento.

Aprendizado few-shot: Capacidade de realizar uma tarefa utilizando uma pequena quantidade de exemplos fornecidos como entrada.

Aprendizado zero-shot: Capacidade de realizar uma tarefa para a qual o modelo não recebeu exemplos específicos durante a entrada ou adaptação para aquela tarefa.

Autoatenção: Mecanismo que permite ao modelo determinar a importância de diferentes palavras ou tokens em relação às outras palavras de uma sequência, ajudando a capturar relações e dependências contextuais.

Codificador (Encoder): Parte da arquitetura Transformer original responsável por processar o texto de entrada e transformá-lo em representações numéricas.

Comportamento emergente: Capacidade de um modelo realizar determinadas tarefas para as quais ele não foi especificamente treinado, como consequência de seu treinamento em grandes quantidades e variedades de dados.

Decodificador (Decoder): Parte da arquitetura Transformer responsável por utilizar as representações processadas para gerar o texto de saída.

DL (Deep Learning): Subárea do Machine Learning baseada em redes neurais profundas. Permite que o modelo aprenda representações e padrões complexos diretamente dos dados.

DNN (Deep Neural Network): Rede neural profunda composta por várias camadas, utilizada para aprender padrões complexos presentes nos dados. Subconjunto de aprendizado de máquina.

GPT (Generative Pre-trained Transformers): Modelo baseado na arquitetura Transformer que utiliza principalmente o submódulo decodificador e é voltado para tarefas de geração de texto.

IA (Inteligência Artificial): Área mais ampla que busca criar sistemas capazes de realizar tarefas que normalmente exigiria algum tipo de inteligência humana, como reconhecer padrões, compreender linguagem e tomar decisões.

LLM (Large Language Model): Modelo de linguagem de grande escala baseado em redes neurais profundas e treinado com grandes quantidades de dados de texto. É capaz de entender, gerar e responder textos, sendo essas tarefas uma das suas principais características.

ML (Machine Learning): Subárea da IA em que algoritmos aprendem padrões a partir de dados para realizar previsões ou tomar decisões, sem que todas as regras precisem ser programadas manualmente.

Modelo autorregressivo: Modelo que utiliza suas próprias saídas anteriores como parte da entrada para realizar previsões futuras.

Predição da próxima palavra (Next word prediction): Tarefa em que o modelo aprende a prever qual será a próxima palavra ou token com base no contexto anterior da sequência.

Pré-treinamento (Pre-training): Primeira etapa do treinamento de uma LLM, na qual o modelo é treinado com um grande e diverso conjunto de textos para desenvolver uma compreensão ampla da linguagem.

Transformer: Arquitetura de rede neural utilizada pela maioria das LLMs modernas. Utiliza mecanismos de atenção para considerar diferentes partes da sequência de entrada ao realizar previsões.

Apêndice A - Introdução ao PyTorch

Autograd: Sistema de diferenciação automática do PyTorch responsável por acompanhar as operações realizadas com tensores e calcular automaticamente os gradientes. Esses gradientes são utilizados durante o treinamento de redes neurais para ajustar os parâmetros do modelo e reduzir o erro das previsões.

Construção de modelos: Processo de criação de modelos de redes neurais utilizando módulos e componentes fornecidos pelo PyTorch, principalmente a classe `torch.nn.Module`. Estes módulos permitem organizar camadas, parâmetros e operações de um modelo, facilitando sua construção, treinamento e reutilização.

Manipulação de dimensões: Conjunto de operações utilizadas para alterar a forma ou a organização das dimensões de um tensor sem necessariamente modificar seus valores. Permitem adaptar os dados ao formato esperado por diferentes operações e camadas de uma rede neural.

Operações básicas: Operações matemáticas realizadas diretamente sobre tensores, como soma, subtração, multiplicação, divisão, soma dos elementos (`sum`), média (`mean`) e

identificação do maior valor (max). Essas operações permitem manipular e calcular informações armazenadas nos tensores.

Operações matriciais: Operações matemáticas realizadas entre matrizes e tensores, como multiplicação de matrizes, produto de matrizes e transposição. São fundamentais em redes neurais, pois muitos cálculos realizados durante o processamento dos dados envolvem operações matriciais.

Tensores: Tensores representam um conceito matemático que generaliza vetores e matrizes para dimensões potencialmente superiores. Do ponto de vista computacional, os tensores funcionam como contêineres de dados. Por exemplo, eles armazenam dados multidimensionais, nos quais cada dimensão representa uma característica diferente.