

GLOSSÁRIO

Glossário de Termos abordados no capítulo 2 do livro “Build a Large Language Model (from scratch)”

Absolute Positional Embedding (Embedding Posicional Absoluto): Forma de representar a posição de cada token atribuindo um vetor específico para cada posição da sequência. Permite que o modelo identifique a posição exata de cada token no texto.

Alvo (Target): Sequência de tokens que o modelo deve aprender a prever durante o treinamento. Em modelos GPT, o alvo normalmente corresponde aos tokens da sequência de entrada deslocados uma posição para a frente.

Amostragem de dados (Data Sampling): Processo de selecionar e organizar partes de um conjunto de dados para formar exemplos utilizados no treinamento de uma LLM. No capítulo, a amostragem é realizada utilizando uma janela deslizante sobre os tokens.

Batch (Lote): Conjunto de exemplos processados simultaneamente pelo modelo durante uma etapa de treinamento. O uso de batches permite processar vários exemplos de uma vez e influencia o consumo de memória e a estabilidade das atualizações do modelo.

Batch size (Tamanho do lote): Quantidade de exemplos processados em cada batch. É um hiperparâmetro do treinamento e pode influenciar o uso de memória e o comportamento das atualizações dos parâmetros do modelo.

BOS (Beginning of Sequence): Token especial utilizado para indicar o início de uma sequência de texto. Pode ser utilizado para informar explicitamente ao modelo onde uma sequência começa.

BPE (Byte Pair Encoding): Algoritmo de tokenização que divide palavras em unidades menores, como sub palavras e caracteres, realizando posteriormente combinações frequentes dessas unidades. É utilizado em modelos como GPT e permite lidar com palavras que não aparecem diretamente no vocabulário.

Codificador (Encoder): Componente de um tokenizer responsável por transformar um texto em tokens e convertê-los em identificadores numéricos, chamados de token IDs.

Codificação one-hot (One-Hot Encoding): Forma de representação em que cada token é representado por um vetor no qual uma posição possui o valor 1 e as demais possuem o valor 0. A camada de embedding permite obter os vetores dos tokens de maneira mais eficiente sem precisar realizar explicitamente essa representação.

Contexto: Conjunto de informações presentes ao redor de um token em uma sequência. O contexto ajuda o modelo a interpretar o significado dos tokens considerando as demais partes do texto.

DataLoader: Componente utilizado para organizar e fornecer os dados de treinamento em batches. No capítulo, é utilizado para percorrer o conjunto de dados e retornar tensores contendo as sequências de entrada e seus respectivos alvos.

Decodificador (Decoder): Componente responsável por transformar token IDs novamente em tokens de texto e reconstruir a sequência textual. Em um tokenizer, realiza o processo inverso ao codificador.

Dimensão do embedding: Quantidade de valores que compõem o vetor utilizado para representar um token. Embeddings podem possuir diferentes dimensões, sendo que dimensões maiores podem representar relações mais complexas, mas aumentam o custo computacional.

Embedding: Representação de um dado, como um token, por meio de um vetor de valores contínuos que pode ser processado matematicamente por uma rede neural.

Embedding de palavra (Word Embedding): Representação vetorial utilizada para representar palavras ou tokens. Palavras que possuem relações semânticas ou aparecem em contextos semelhantes podem apresentar vetores próximos no espaço de embeddings.

Embedding posicional (Positional Embedding): Representação vetorial utilizada para adicionar informações sobre a posição dos tokens em uma sequência. Enquanto o token embedding representa o que é o token, o embedding posicional representa onde ele está.

EOS (End of Sequence): Token especial utilizado para indicar o final de uma sequência de texto.

Espaço de embedding (Embedding Space): Espaço matemático no qual os tokens são representados por vetores. Tokens com características ou relações semelhantes podem ocupar posições próximas nesse espaço.

Geração aumentada por recuperação (Retrieval-Augmented Generation — RAG): Técnica que combina a recuperação de informações de uma fonte externa com a geração de texto. O modelo recupera informações relevantes e utiliza esse conteúdo para auxiliar na geração de uma resposta.

GPT (Generative Pre-trained Transformer): Família de modelos de linguagem baseada na arquitetura Transformer. Os modelos GPT utilizam uma abordagem auto regressiva para prever o próximo token com base nos tokens anteriores.

Hiperparâmetro: Valor definido para configurar o processo de treinamento e que não é aprendido diretamente pelo modelo. Batch size e stride são exemplos de parâmetros utilizados na preparação e no treinamento dos dados.

ID do token (Token ID): Número inteiro utilizado para representar um token dentro do vocabulário. Cada token possui um identificador único que permite convertê-lo posteriormente em uma representação vetorial.

Input embedding: Representação vetorial final fornecida à LLM como entrada, obtida a partir da combinação dos embeddings dos tokens com as informações posicionais.

Janela deslizante (Sliding Window): Técnica utilizada para percorrer uma sequência de tokens e extrair blocos de texto que serão utilizados como exemplos de treinamento. A quantidade de posições avançadas a cada movimento é determinada pelo stride.

Janela de contexto: Quantidade de tokens considerada pelo modelo em uma determinada sequência de entrada. Define a quantidade de texto que pode ser processada simultaneamente como contexto.

LLM (Large Language Model): Modelo de linguagem de grande escala treinado com grandes quantidades de dados textuais para aprender padrões da linguagem e realizar tarefas como geração, compreensão e transformação de texto.

Máscara (Mask): Mecanismo utilizado para impedir que determinadas posições ou tokens sejam considerados em uma operação. Durante o treinamento em batches, pode ser utilizada para ignorar tokens adicionados apenas para preenchimento.

Matriz de embeddings: Matriz de pesos que armazena os vetores associados aos tokens do vocabulário. Cada linha da matriz corresponde ao embedding de um determinado token.

PAD (Padding Token): Token especial utilizado para preencher sequências menores, fazendo com que tenham o mesmo tamanho das maiores dentro de um batch. Isso permite que diferentes sequências sejam processadas simultaneamente.

Par entrada-alvo: Par formado por uma sequência de tokens utilizada como entrada do modelo e outra sequência que contém os tokens que o modelo deve prever. Em modelos GPT, o alvo é obtido deslocando a sequência de entrada uma posição para a frente.

Posição relativa (Relative Position): Forma de representar a posição de um token considerando sua relação com os demais tokens da sequência, como a distância entre duas posições, em vez de considerar apenas a posição absoluta.

Pré-processamento: Conjunto de etapas realizadas antes de fornecer os dados à LLM. No capítulo, envolve a tokenização, criação dos token IDs, formação dos pares de entrada e alvo e conversão dos IDs em embeddings.

Pré-treinamento (Pretraining): Etapa em que uma LLM é treinada com grandes quantidades de dados para aprender padrões gerais da linguagem. Em modelos GPT, uma das principais tarefas é prever o próximo token de uma sequência.

Retropropagação (Backpropagation): Algoritmo utilizado para calcular os gradientes dos parâmetros de uma rede neural a partir do erro produzido pelo modelo. Esses gradientes são utilizados para atualizar os parâmetros durante o treinamento.

Self-attention (Autoatenção): Mecanismo que permite ao modelo analisar as relações entre diferentes tokens de uma sequência, identificando quais informações do contexto são mais relevantes para cada token.

Sequência: Conjunto ordenado de tokens que representa uma parte do texto. A ordem dos tokens é importante porque alterações na sequência podem modificar o significado do texto.

Stride: Quantidade de posições que a janela deslizante avança ao criar novos exemplos de treinamento. Um stride menor produz maior sobreposição entre os exemplos, enquanto um stride maior reduz a sobreposição.

Subpalavra (Subword): Unidade menor que uma palavra completa utilizada durante a tokenização. Uma palavra pode ser dividida em uma ou várias subpalavras, permitindo que o modelo represente palavras que não estão presentes integralmente no vocabulário.

Tamanho do vocabulário: Quantidade total de tokens diferentes presentes no vocabulário utilizado pelo tokenizer. Cada token possui um ID único associado.

TIKTOKEN: Biblioteca desenvolvida para realizar de maneira eficiente a tokenização utilizando o algoritmo BPE. Ela permite codificar textos em token IDs e decodificar token IDs novamente em texto.

Token: Unidade básica utilizada para representar uma parte de um texto que será processada por uma LLM. Dependendo do método de tokenização, um token pode representar uma palavra, parte de uma palavra, um caractere ou um símbolo especial.

Token especial: Token criado para representar uma função específica durante o processamento do texto, como indicar o início ou fim de uma sequência, preencher espaços ou representar uma palavra desconhecida.

Token embedding: Vetor numérico utilizado para representar um token. Ele fornece informações sobre o conteúdo ou identidade do token, mas não indica, por si só, sua posição na sequência.

Token ID: Identificador numérico inteiro associado a cada token do vocabulário. É utilizado como representação intermediária entre a tokenização do texto e a criação dos embeddings.

Tokenização (Tokenization): Processo de dividir um texto em unidades menores chamadas tokens. Essa é uma etapa necessária para transformar o texto em uma representação que possa ser processada por uma LLM.

Tokenizer: Componente responsável por realizar a tokenização e converter textos em tokens e token IDs, além de realizar o processo inverso durante a decodificação.

Unknown token (unk): Token especial utilizado para representar palavras ou símbolos que não estão presentes no vocabulário. No BPE utilizado por modelos GPT, palavras desconhecidas podem ser divididas em sub palavras ou caracteres, reduzindo a necessidade desse token.

Vocabulário: Conjunto de tokens únicos reconhecidos pelo tokenizer, no qual cada token é associado a um identificador numérico exclusivo. O vocabulário funciona como um mapeamento entre tokens e tokens IDs.

Vocabulário inverso: Estrutura que realiza o processo contrário ao vocabulário, associando cada token ID ao token correspondente. É utilizada para converter a representação numérica novamente em texto durante a decodificação.

Word2Vec: Técnica baseada em redes neurais utilizada para aprender representações vetoriais de palavras a partir dos contextos em que elas aparecem. A ideia central é que palavras que aparecem em contextos semelhantes tendem a possuir significados semelhantes e, consequentemente, embeddings próximos.