

GLOSSÁRIO

Glossário de Termos abordados no capítulo 3 do livro “Build a Large Language Model (from scratch)”

Attention (Atenção): Mecanismo que permite ao modelo identificar quais partes de uma sequência são mais relevantes para entender uma determinada palavra ou posição.

Attention Score (Pontuação de Atenção): Valor calculado para indicar o quanto uma palavra está relacionada a outra durante o mecanismo de atenção. Quanto maior o score, maior tende a ser a relação entre os vetores comparados.

Attention Weights (Pesos de Atenção): Valores obtidos normalmente após aplicar o softmax aos attention scores. Indicam quanto cada token deve contribuir para formar o vetor de contexto de outro token. Os pesos de uma mesma linha somam 1.

Bahdanau Attention (Atenção de Bahdanau): Mecanismo de atenção desenvolvido para melhorar arquiteturas encoder-decoder baseadas em RNNs. Permite que o decoder acesse seletivamente diferentes partes da sequência de entrada durante a geração.

Bias: Valor adicional aprendido por uma camada de uma rede neural, como `nn.Linear`. Pode ser desativado usando `bias=False`.

Causal Attention (Atenção Causal): Forma de self-attention que impede o modelo de olhar para tokens futuros. Ao prever um token, o modelo só pode utilizar os tokens anteriores e o token atual.

Causal Mask (Máscara Causal): Máscara utilizada no causal attention para bloquear o acesso aos tokens futuros. As posições bloqueadas recebem valores como `-inf` antes do softmax e, por isso, recebem peso zero na atenção.

Context Vector (Vetor de Contexto): Representação de um token enriquecida com informações relevantes dos outros tokens da sequência. É obtido combinando os vetores Value usando os pesos de atenção.

Decoder: Parte de uma arquitetura encoder-decoder responsável por gerar a sequência de saída. Em uma tradução, por exemplo, ele utiliza as informações recebidas do encoder para produzir a tradução.

Dot Product (Produto Escalar): Operação matemática que multiplica os elementos correspondentes de dois vetores e soma os resultados. Na atenção, é utilizado para medir o grau de alinhamento entre dois vetores.

Dropout: Técnica utilizada durante o treinamento para desligar aleatoriamente algumas conexões ou valores do modelo. Ajuda a reduzir o overfitting e evitar que o modelo dependa demais de determinadas informações.

Embedding: Representação numérica de um token ou palavra na forma de um vetor. Permite que o computador trabalhe matematicamente com palavras e outros elementos do texto.

Encoder: Parte de uma arquitetura encoder-decoder que recebe e processa a sequência de entrada, transformando-a em representações numéricas que podem ser utilizadas pelo decoder.

Head (Cabeça de Atenção): Uma parte individual do mecanismo de Multi-Head Attention. Cada head pode aprender diferentes relações entre os tokens da sequência.

Hidden State (Estado Oculto): Representação interna utilizada principalmente em redes recorrentes, como RNNs, para carregar informações sobre o que foi processado anteriormente.

Information Leakage (Vazamento de Informação): Situação em que o modelo consegue acessar informações que deveria desconhecer durante uma previsão. No treinamento de modelos causais, a máscara evita que tokens futuros influenciem a previsão atual.

Key (Chave): Uma das três representações utilizadas na atenção. Pode ser entendida como a informação que indica que tipo de informação um token possui e é comparada com a Query para determinar sua relevância.

LLM (Large Language Model): Modelo de linguagem de grande escala treinado com grandes quantidades de texto para aprender padrões da linguagem e realizar tarefas como geração e compreensão de texto.

Mask (Máscara): Mecanismo utilizado para bloquear determinadas posições durante o cálculo da atenção. No causal attention, impede que um token veja os tokens que aparecem depois dele.

Matrix Multiplication (Multiplicação de Matrizes): Operação matemática utilizada para realizar vários cálculos de forma eficiente. Na atenção, permite substituir vários loops for por operações vetorizadas.

Multi-Head Attention (Atenção Multi-Cabeça): Extensão do self-attention que divide o mecanismo de atenção em várias heads. Cada head pode aprender diferentes relações entre os tokens e seus resultados são posteriormente combinados.

MultiHeadAttention: Implementação do Multi-Head Attention em que todas as heads são organizadas dentro de uma única classe. Os dados são reorganizados em várias heads usando operações como `view()` e `transpose()`.

Multi Head Attention Wrapper: Implementação mais simples do Multi-Head Attention que cria vários objetos CausalAttention separadamente e depois concatena os resultados produzidos por cada head.

Overfitting (Sobreajuste): Situação em que o modelo aprende muito bem os dados de treinamento, mas apresenta dificuldade para lidar com dados novos. Nesse caso, o modelo tem dificuldade para generalizar.

Parameter / Weight Parameter: Valor que o modelo aprende durante o treinamento. As matrizes W_q , W_k e W_v , por exemplo, possuem valores que são ajustados durante o treinamento.

Query (Consulta): Uma das três representações utilizadas na atenção. Pode ser entendida como a pergunta ou informação que um token está procurando nas outras partes da sequência.

Q (Query): Vetor criado a partir do embedding de entrada usando a matriz de pesos W_q . É utilizado para procurar informações relevantes nas Keys.

RNN (Recurrent Neural Network): Tipo de rede neural que processa sequências de forma recorrente, utilizando informações de etapas anteriores por meio do hidden state. Foi muito utilizada em processamento de linguagem antes da popularização dos Transformers.

Renormalização: Processo de ajustar novamente os pesos de atenção depois que algumas posições foram bloqueadas pela máscara. Dessa forma, os pesos das posições permitidas continuam somando 1.

Scaled Dot-Product Attention (Atenção por Produto Escalar Escalonado): Forma de calcular a atenção que divide os attention scores pela raiz quadrada da dimensão das Keys ($\sqrt{d_k}$) antes de aplicar o softmax. Isso ajuda a evitar valores muito grandes e problemas com os gradientes.

Self-Attention (Autoatenção): Mecanismo no qual cada token pode considerar outros tokens da própria sequência para criar uma representação contextualizada. A sequência utiliza informações dela mesma para entender as relações entre seus elementos.

Simplified Self-Attention (Self-Attention Simplificado): Versão simplificada do mecanismo de atenção utilizada para entender seu funcionamento básico antes da introdução das matrizes de pesos treináveis.

Softmax: Função que transforma os attention scores em valores entre 0 e 1 que representam pesos normalizados. Os valores produzidos pelo softmax de uma mesma distribuição somam 1.

Token: Unidade de texto processada pelo modelo. Pode representar uma palavra, parte de uma palavra, um sinal de pontuação ou outro fragmento de texto.

Transformer: Arquitetura de rede neural baseada principalmente em mecanismos de atenção. É a arquitetura utilizada como base para muitos modelos modernos de linguagem, incluindo modelos GPT.

Transpose: Operação que troca a posição de duas dimensões de um tensor. No Multi-Head Attention, ajuda a organizar os dados para realizar os cálculos de atenção separadamente para cada head.

Value (Valor): Uma das três representações utilizadas na atenção. Representa a informação que será utilizada para construir o vetor de contexto depois que os pesos de atenção forem calculados.

V (Value): Vetor criado a partir do embedding de entrada usando a matriz de pesos W_v . Os Values são combinados usando os attention weights para produzir o vetor de contexto.

W_q (Matriz de Pesos da Query): Matriz de pesos treinável utilizada para transformar um embedding de entrada em uma Query. A operação pode ser representada como $Q = xW_q$.

W_k (Matriz de Pesos da Key): Matriz de pesos treinável utilizada para transformar um embedding de entrada em uma Key. A operação pode ser representada como $K = xW_k$.

W_v (Matriz de Pesos do Value): Matriz de pesos treinável utilizada para transformar um embedding de entrada em um Value. A operação pode ser representada como $V = xW_v$.

Weight Parameters x Attention Weights (Parâmetros de Peso x Pesos de Atenção): Os weight parameters são valores aprendidos pelo modelo, como os valores das matrizes W_q , W_k e W_v . Já os attention weights são valores calculados durante o processamento para indicar quanto cada token deve contribuir para o contexto de outro token.

X (Vetor de Entrada): Representação numérica de um token antes de ser transformado em Query, Key e Value. Um mesmo vetor de entrada pode ser utilizado para gerar os três tipos de representação.

Z (Vetor de Contexto): Resultado produzido pelo mecanismo de atenção depois que os Values são combinados usando os attention weights. Representa o token considerando informações relevantes do restante da sequência.