

SPRINT 3

QUIZ

Aluna: Ana Clara Viganó P. de Oliveira - 412887 **Aluna:** Jasmine Masson Alves - 427466

Questões

1. Qual operação é utilizada para calcular a semelhança entre uma query e uma key?
 - (a) Soma elemento por elemento.
 - (b) Produto escalar.
 - (c) Divisão inteira.
 - (d) Multiplicação de matrizes sem transposição.
2. Qual é a função da operação softmax aplicada aos scores de atenção?
 - (a) Transformar os scores em pesos que somam aproximadamente 1.
 - (b) Transformar todos os scores em números negativos.
 - (c) Remover completamente os valores maiores.
 - (d) Diminuir a quantidade de tokens da sequência.
3. Qual é a finalidade do mascaramento causal?
 - (a) Permitir que cada token veja tokens futuros.
 - (b) Impedir que um token observe informações futuras.
 - (c) Remover o primeiro token da sequência.
 - (d) Fazer todos os pesos de atenção serem iguais.

4. Considere uma entrada com formato

$(2, 8, 3)$.

O que cada dimensão representa?

- (a) 2 tokens, 8 lotes e 3 cabeças.
 - (b) 2 lotes, 8 tokens e 3 dimensões por token.
 - (c) 2 cabeças, 8 dimensões e 3 lotes.
 - (d) 2 dimensões, 8 cabeças e 3 tokens.
5. Em uma implementação de Causal Attention, o modelo precisa garantir que, ao calcular a representação de um determinado token, ele não tenha acesso às informações dos tokens que aparecem posteriormente na sequência. Para isso, o código cria uma máscara triangular superior utilizando `torch.triu()`, substitui as posições futuras por `-torch.inf` e, somente depois, aplica `torch.softmax()` aos scores de atenção. Considerando esse processo, por que a aplicação da máscara antes do *softmax* é importante?
- (a) Porque transformar os scores das posições futuras em `-inf` faz com que essas posições recebam peso zero após o *softmax*, impedindo que informações futuras contribuam para o vetor de contexto do token atual.
 - (b) Porque a máscara remove fisicamente os tokens futuros da sequência, diminuindo o tamanho do tensor antes do cálculo dos pesos de atenção e tornando o processamento mais rápido.
 - (c) Porque o *softmax* transforma todas as posições futuras em valores positivos maiores que os demais, fazendo com que o modelo consiga identificar quais tokens ainda precisam ser processados.
 - (d) Porque a máscara substitui o cálculo de Query, Key e Value, permitindo que a Causal Attention determine diretamente quais tokens devem participar da sequência sem precisar calcular os scores.
6. Quais componentes são utilizados no cálculo de atenção?
- (a) Queries e keys.
 - (b) Keys e values.
 - (c) Values, queries e keys.
 - (d) Apenas os tokens futuros.
7. Sobre o mecanismo de Causal Attention, assinale as alternativas corretas.
- (a) Utiliza uma máscara para bloquear informações futuras.
 - (b) Pode ser utilizado em modelos geradores de texto.
 - (c) Utiliza softmax para calcular os pesos de atenção.
 - (d) Permite que todos os tokens observem toda a sequência futura.

8. Sobre a implementação de Multi-Head Attention, assinale as alternativas corretas.

- (a) A saída de cada cabeça pode representar diferentes padrões de atenção.
- (b) O valor de d_{out} deve ser divisível pelo número de cabeças.
- (c) Os vetores podem ser reorganizados utilizando a operação **view**.
- (d) Todas as cabeças obrigatoriamente produzem exatamente os mesmos valores.

9. Quais afirmações sobre as matrizes de atenção estão corretas?

- (a) Cada linha representa os pesos de atenção de um token.
- (b) Cada coluna representa um token que pode receber atenção.
- (c) Em atenção causal, as posições acima da diagonal principal são bloqueadas.
- (d) Os valores dos pesos de uma linha válida normalmente somam aproximadamente 1 antes do dropout.

10. Considere uma entrada com formato

$(1, 8, 8)$

e uma Multi-Head Attention com quatro cabeças. Assinale as alternativas corretas.

- (a) O lote possui apenas uma sequência.
- (b) A sequência possui oito tokens.
- (c) Cada token possui oito dimensões de entrada.
- (d) Cada cabeça possui duas dimensões quando $d_{\text{out}} = 8$.