GLOSSÁRIO

Glossário de Termos abordados no capítulo 4 do livro "Build a Large Language Model (from scratch)"

Activation Function (Função de Ativação): Função matemática aplicada aos valores de uma rede neural para introduzir não linearidade, permitindo que o modelo aprenda relações e padrões complexos nos dados.

Batch Normalization (Normalização em Lotes): Técnica que normaliza as ativações considerando estatísticas calculadas sobre um lote de exemplos. Diferentemente da Layer Normalization, seu cálculo depende dos dados presentes no batch.

DummyGPTModel: Implementação simplificada de uma arquitetura GPT, utilizada para compreender a estrutura geral e o fluxo de dados do modelo. Inclui embeddings de tokens e posições, dropout, blocos Transformer, normalização final e uma camada linear de saída.

Embedding (Representação Vetorial): Representação numérica de um token por meio de um vetor de valores aprendidos durante o treinamento. Permite que o modelo processe matematicamente os elementos do texto.

FeedForward (Rede de Alimentação Direta): Módulo presente nos blocos Transformer que processa individualmente a representação de cada posição da sequência. Geralmente expande a dimensão dos vetores, aplica uma função de ativação e depois retorna à dimensão original, permitindo aprender padrões mais complexos.

Forward Method (Método Forward): Método que define como os dados percorrem as camadas de uma rede neural durante a execução do modelo. Em PyTorch, é implementado pelo método forward().

GELU (Gaussian Error Linear Unit): Função de ativação utilizada em modelos como o GPT-2. Introduz não linearidade de maneira suave, permitindo que valores negativos também contribuam para o processamento, diferentemente da ReLU, que zera os valores negativos.

Greedy Decoding (Decodificação Gulosa): Estratégia de geração de texto que seleciona, em cada etapa, o token com a maior probabilidade prevista pelo modelo. É simples e rápida, mas pode produzir textos repetitivos ou previsíveis.

Layer Normalization (Normalização de Camada): Técnica que normaliza as ativações de cada exemplo individualmente, considerando suas características ao longo de uma dimensão definida. Ajuda a estabilizar o treinamento e facilita o processamento em redes profundas, como os Transformers.

LayerNorm: Camada que implementa a normalização de camada. No GPT-2, é utilizada nos blocos Transformer e antes da camada final de saída para manter as ativações em uma escala mais estável.

Linear Layer (Camada Linear): Camada de rede neural que transforma os valores de entrada por meio de uma multiplicação por uma matriz de pesos, podendo também adicionar um bias. No GPT, é utilizada em módulos como FeedForward e na previsão do próximo token.

Logits: Valores numéricos não normalizados produzidos pelo modelo para representar a pontuação atribuída a cada token possível na próxima posição da sequência. São normalmente transformados em probabilidades usando a função softmax.

Model Parameters (Parâmetros do Modelo): Valores internos treináveis de uma rede neural, como os elementos das matrizes de pesos e os valores de bias. São ajustados durante o treinamento para que o modelo aprenda padrões presentes nos dados.

Next-Token Prediction (Previsão do Próximo Token): Tarefa central dos modelos GPT, na qual o modelo utiliza o contexto disponível para calcular qual token tem maior probabilidade de aparecer em seguida.

Normalization (Normalização): Processo de ajuste dos valores de uma representação numérica para manter suas características em uma escala adequada ao processamento. Nas redes neurais profundas, técnicas de normalização podem melhorar a estabilidade do treinamento.

Output Head (Camada de Saída): Camada que transforma as representações finais dos tokens em logits, produzindo pontuações para os tokens do vocabulário. Essas pontuações são utilizadas para calcular as probabilidades do próximo token.

Pre-LayerNorm (Normalização Antes da Camada): Organização arquitetural em que a normalização é aplicada antes dos principais submódulos do Transformer, como a atenção e a rede FeedForward. Favorece a estabilidade do treinamento e o fluxo dos gradientes em redes profundas.

ReLU (Rectified Linear Unit): Função de ativação que transforma valores negativos em zero e mantém os valores positivos. É uma função não linear bastante utilizada em redes neurais.

Shortcut Connections (Conexões de Atalho): Caminhos alternativos que permitem que a entrada de um submódulo seja somada à sua saída processada. Ajudam a preservar informações e facilitam a propagação dos gradientes durante o treinamento de redes profundas.

SwiGLU (Swish-Gated Linear Unit): Variante de módulo de alimentação direta que combina transformações lineares com uma função de ativação e um mecanismo de controle por portas (*gating*). É utilizada em algumas arquiteturas modernas de redes neurais para melhorar a capacidade de representação.

Tokenizer (Tokenizador): Componente que divide o texto em tokens e converte esses tokens em identificadores numéricos. No tokenizador do GPT-2, uma palavra pode corresponder a um único token ou ser dividida em fragmentos menores

Transformer Block (Bloco Transformer): Unidade fundamental da arquitetura GPT. Combina mecanismos de atenção, uma rede FeedForward, normalização, dropout e conexões residuais para transformar as representações dos tokens e incorporar informações contextuais.

Vanishing Gradient (Desaparecimento do Gradiente): Problema que ocorre quando os gradientes ficam muito pequenos durante a retropropagação, dificultando o ajuste dos parâmetros das camadas iniciais de uma rede profunda.

Weight Tying (Compartilhamento de Pesos): Técnica em que duas camadas utilizam a mesma matriz de pesos. No GPT-2 original, a matriz da camada de embeddings de tokens pode ser

compartilhada com a matriz da camada de saída, reduzindo o número de parâmetros distintos e o uso de memória.

Weight Matrix (Matriz de Pesos): Matriz que contém os parâmetros utilizados por uma camada neural para transformar os dados. Por exemplo, uma matriz com dimensões 2.048 × 2.048 possui 4.194.304 elementos, cada um correspondente a um parâmetro.

Geração Autoregressiva (Autoregressive Generation): Processo em que o modelo gera um token por vez e adiciona cada novo token ao contexto utilizado para prever o seguinte. Esse ciclo se repete até atingir um limite ou uma condição de parada.

Greedy Search: Estratégia de busca que escolhe a opção de maior valor em cada etapa, sem explorar sistematicamente outras sequências possíveis. Na geração de texto, corresponde à escolha gulosa do próximo token.

Logit: Pontuação numérica atribuída pelo modelo a um token possível antes da conversão em probabilidade. Um logit maior não é, por si só, uma probabilidade, embora influencie o resultado da função softmax.

Sampling (Amostragem): Estratégia de geração em que o próximo token é selecionado aleatoriamente de acordo com uma distribuição de probabilidades, em vez de escolher sempre o token mais provável. Dependendo da configuração, pode produzir textos mais variados.

Sequence (Sequência): Conjunto ordenado de tokens que representa um fragmento de texto. O modelo utiliza a sequência de entrada como contexto para calcular as previsões seguintes.

Training (Treinamento): Processo em que o modelo ajusta seus parâmetros utilizando dados e uma função de perda. O objetivo é melhorar a capacidade de realizar previsões e aprender padrões presentes nos dados.

Vector Dimension (Dimensão do Vetor): Quantidade de elementos de um vetor. No GPT-2 de 124 milhões de parâmetros, a dimensão dos embeddings é 768, ou seja, cada token é representado internamente por um vetor com 768 valores.