GLOSSÁRIO

Glossário de Termos abordados no capítulo 5 do livro “Build a Large Language Model (from scratch)”

Weight parameters (Parâmetros de peso): Pesos são os parâmetros treináveis que o processo de aprendizagem ajusta. No PyTorch, eles são armazenados em camadas lineares.

Logits: Vetores representando a probabilidade de distribuição para cada token no vocabulário.

Loss (Perda): Métrica que acessa numericamente a qualidade do texto gerado durante o treinamento. Mede exatamente a distância entre a resposta correta e o “chute” que o modelo deu.

Targets (Alvos): São as entradas do modelo deslocadas uma posição à frente. Isso é essencial para ensinar o modelo a prever o próximo token em uma sequência.

Backpropagation: Método usado para fazer o ajuste de pesos. O modelo olha para o resultado final, entende o tamanho do erro (medido pelo loss) e vai ajustando suas configurações de trás para frente para não errar na próxima vez.

Cross entropy loss: Fórmula matemática famosa na Inteligência Artificial usada para calcular o erro (loss). Ela mede exatamente a distância entre as probabilidades que o modelo deu para cada palavra e a palavra 100% correta.

Perplexity (Perplexidade): Forma de medir o erro do modelo que traduz a matemática complexa do loss para o tamanho da confusão do modelo. Quanto menor esse número, melhor o modelo.

Batches (Lotes/Pacotes): Pequenos pacotes agrupados compostos por fatias menores e embaralhadas do texto, que são enviados para o modelo começar a treinar e aprender padrões em vez de apenas decorar frases.

AdamW: Algoritmo utilizado para ajustar os pesos de uma rede neural durante o treinamento. É uma versão aprimorada do Adam que utiliza o Weight Decay para ajudar o modelo a aprender melhor e reduzir o risco de overfitting.

Weight Decay: Técnica utilizada para evitar que os pesos do modelo fiquem muito grandes.

Overfitting (Sobreajuste): Acontece quando o modelo aprende muito bem os dados de treinamento, mas tem dificuldade em lidar com dados novos.

Decoding strategies (Estratégias de geração de texto): Diferentes abordagens para selecionar a próxima palavra na geração de texto, como temperature scaling e top-k sampling.

Temperature scaling: Estratégia de geração que troca a regra rígida de escolha (maior probabilidade) por um "sorteio" baseado nas porcentagens, permitindo que o modelo construa frases diferentes ao fazer a mesma pergunta.

Top-k sampling: Estratégia que restringe os tokens de amostra para os top-k mais prováveis, excluindo todos os outros do processo de seleção ao mascarar seus scores de probabilidade.

Weight tying: Técnica que compartilha e utiliza os mesmos pesos da camada de entrada (que transforma as palavras em números) na camada de saída (que escolhe a próxima palavra), em vez de criar pesos diferentes para cada uma.

Pré-treinamento (Pretraining): A fase inicial em que o modelo é exposto a uma vasta quantidade de textos para aprender as regras gerais do idioma, a gramática e os fatos do mundo, tendo como objetivo principal prever a próxima palavra da sequência.

Dados não rotulados: Textos puros coletados (como artigos, livros e sites) que não possuem anotações, marcações ou respostas prontas feitas por humanos. O modelo aprende a partir da própria estrutura do texto fornecido.

Epoch (Época): Representa um ciclo completo em que o modelo de Inteligência Artificial processa e aprende com todo o conjunto de dados de treinamento disponível.

Gradientes: Valores matemáticos calculados durante o *backpropagation* que indicam a direção exata e a intensidade em que os pesos do modelo devem ser alterados para que o erro (loss) diminua na próxima tentativa.

Tokenizer / Tokenização: Ferramenta e processo responsáveis por fatiar o texto de entrada em unidades menores (tokens) e codificá-las em números (Token IDs), que são a linguagem que o modelo consegue ler e processar.

Vocabulário: O "dicionário" completo de tokens únicos que o modelo conhece. Ao tentar prever a próxima palavra, o modelo distribui probabilidades entre todos os elementos desse vocabulário.

Softmax: Função matemática aplicada aos *logits* que transforma esses valores brutos em porcentagens (probabilidades). É ela que permite visualizar qual token tem, por exemplo, 80% de chance de ser o próximo e qual tem apenas 1%.

Argmax: Operação utilizada durante a avaliação do modelo que localiza o índice (posição) com o maior valor de probabilidade em um vetor. É a regra rígida que escolhe a palavra mais provável se não usarmos as *decoding strategies*.

Conjunto de Treinamento e Validação: A divisão dos dados em duas partes: uma para as sessões de estudo onde os pesos são ajustados (treinamento) e outra que funciona como uma "prova" (validação) para checar se o modelo realmente aprendeu a generalizar ou se apenas decorou o texto.

Self-supervised learning (Aprendizado autossupervisionado): A técnica que torna o pré-treinamento possível com dados não rotulados. O próprio texto fornece a resposta correta (o alvo/target), já que o objetivo é simplesmente prever a palavra seguinte baseando-se nas palavras anteriores.